

# PV Fault Detection AI Model

Solar panel fault detection artificial intelligence model

1<sup>st</sup> İsmail Akça(21040301033)  
Mühendislik Fakültesi  
İstanbul Topkapı Üniversitesi  
İstanbul, Türkiye  
[ismailakca@stu.topkapi.edu.tr](mailto:ismailakca@stu.topkapi.edu.tr)

2<sup>nd</sup> Muhammet Emir  
Şimşek(21040301005)  
Mühendislik Fakültesi  
İstanbul Topkapı Üniversitesi  
İstanbul, Türkiye  
[muhammedemirsimsek@stu.topkapi.edu.tr](mailto:muhammedemirsimsek@stu.topkapi.edu.tr)  
[u.tr](http://u.tr)

3<sup>rd</sup> Cevat Rahebi  
Mühendislik Fakültesi  
İstanbul Topkapı Üniversitesi  
İstanbul, Türkiye  
[cevatrahebi@stu.topkapi.edu.tr](mailto:cevatrahebi@stu.topkapi.edu.tr)

**Özet**—Güneş enerjisi gelecekteki enerji talebini karşılamanın önemli yollarından birisidir. Son yıllarda Güneş enerjisinden alınmak istenen verim arttıkça solar panellerin kullanımı ve önemi de artmıştır ancak herhangi bir arıza durumunda bu panellerin oluşabilecek doğal ve doğal olmayan verim düşüklüğünün sebebini tespit etmek için gerekli olan tedbirlerin alımı işgücü maliyetinin artması sebebi ile yetersiz kalmaktadır. Bu makale, solar panellerin görüntüleri kullanılarak doğal ve doğal olmayan sorunların tespitini yapan bir modeli tanıtmaktadır. Bu model Güneş panelleri modüllerinde meydana gelen arızaların erken teşhisini ve sınıflandırılmasını sağlar. Ayrıca, arızanın türünün belirlenmesine de yardımcı olur. Elde edilen sonuçlar, geniş yapay zekanın bu tür sorunların tespitinde en yüksek doğruluk oranını sağladığını ve hesaplama süresini en aza indirdiğini göstermektedir.

**Anahtar Kelimeler**—yapay zeka, model, solar panel, güneş, enerji, maliyet, işgücü, gelecek

## I. GİRİŞ

Günümüzde güneş enerjisi yenilenebilir enerji kaynakları arasında en önemli kaynakların başında gelmektedir ve önemi her geçen gün giderek artmaktadır. Artışın sebebi Dünyanın ekolojik dengesini bozmadan yüksek verimlilikle enerji elde etme sürecindeki en istikrarlı kaynak olmasıdır. Solar paneller sayesinde güneş enerjisi elde etme sürecinde kullanılan panellerin temizliği ve sorunsuzluğu elde edilen enerjinin verimliliği ile doğrudan alakalı bir etken olarak sürece dahil olmaktadır. Türkiye’de güneş enerjisi toplam kurulu güç enerjisi içindeki oranı 8.35% olarak belirlenmiştir 2022 haziran ayında ve bu oran ilerleyen yıllarda hızlı bir şekilde artarak hem dışa bağımlılığın hemde ekolojik düzendeki dengenin korunmasını hedefleyerek ülke gelişiminde önemli bir rol üstlenmesi hedeflenmektedir.[1] Solar panellere etki eden doğrudan ve dolaylı olarak toz, kar ve kuş pislikleri gibi doğal etkenler dışında bu panellerin kullanım ve üretim sürecindeki hatalardan dolayı ortaya çıkabilecek elektrik ve fiziki hasarlar da panellerde sorunlara yol açarak enerji üretiminde verimsizliğe sebep olmaktadır. Bu alandaki sorunu ortadan kaldırmak için geliştirmiş olduğumuz model sayesinde solar panellerin görüntüleri ile modeli eğitmekte kullandığımız sınıflardaki sorunlar tespit edilmektedir. Bu tespit sayesinde yenilenebilir enerji üretme yöntemlerinden biri olan güneş enerjisi sayesinde enerji üreten solar panellerin verimliliği düşük maliyet, yüksek hız ve doğruluk ile optimum seviyede kullanıcılarına yarar sağlamaktadır.

## II. KULLANIM KOLAYLIĞI

### A. Kullanılabileceği yöntemler

Solar panellerin verimliliğini artırmak ve sorunları erken teşhis etmek için geliştirdiğimiz modelin kullanımı son derece kolaydır. Model, sadece solar panellerin görüntülerini kullanarak, panellerdeki olası sorunları hızlı ve etkili bir şekilde tespit etmek için oluşturulmuştur. Kullanıcılar, modeli geliştirdikten sonra oluşturduğumuz model dosyası sayesinde isterlerse basit bir api yazarak istedikleri anda veya bir socket bağlantısı oluşturarak web servis üzerinden sürekli olarak model sayesinde panellerindeki verimi düşürecek sorunları tespit etme yeterliliğine sahip olacaklardır. Kullanım alanında kullanıcıların ihtiyaç duyacağı donanım güçlü bellek kapasitesine sahip bilgisayar ve bu bilgisayara verecekleri görsellerdir bu modeli kullanmak için derin teknik bilgilere sahip olmaları gerekmez bu da modeli maliyet etkinliği açısından önemli bir avantajlı konuma getirir.

### B. Hız ve güvenilirlik

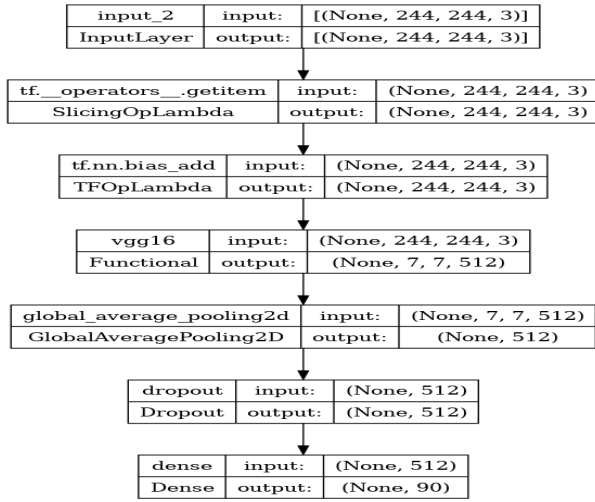
Model, görüntüleri hızlı bir şekilde analiz eder ve kullanıcılara güvenilir sonuçlar sunar. Bu sayede, enerji üretimindeki verimliliği artırmak için hızlı bir şekilde müdahale edilebilir.

### C. Modelin kullanımında yaşanabilecek teknik sorunlar

1. Modelin doğru sonuçlar vermesi için yüklenen görüntülerin yeterli kalitede olması önemlidir. Kullanıcılar, net ve yüksek çözünürlüklü görüntüler sağlamalıdır.

## III. MODEL MIMARISI

Model geliştirme sürecindeki kullanılan yöntem hali hazırda başarılı olan VGG16, Oxford Üniversitesi'nden Visual Geometry Group (VGG) tarafından geliştirilen derin evrişimli sinir ağı (CNN) modelinin fine tuning yöntemi ile internet ortamında bulunan solar panellerdeki hatalardan toplanan görseller ile eğitilmesi ile ilerlemiştir.[2]



#### A. VGG16 Modelinin Avantajları

- Basit ve anlaşılabilir mimariye sahiptir, bu nedenle eğitim ve kullanımı kolaydır.[3]
- Derinlik açısından oldukça etkilidir, bu nedenle karmaşık görüntü verileri üzerinde başarılı sonuçlar verir.[4]
- Fine tuning için yaygın bir modeldir, önceden eğitilmiş ağırlıklar genellikle çeşitli görsel görevlerde başlangıç noktası olarak kullanılır.[5]

#### B. VGG16 Modelinin Dezavantajları

- Çok sayıda parametreye sahip olduğu için, eğitim ve tahmin süreleri uzun olabilir.
- Yüksek bellek ve hesaplama gücü gerektirir, bu nedenle küçük cihazlarda kullanımı sınırlı olabilir.

#### C. VGG16 Modelinin Bize Olan Katkıları

- Önceden eğitilmiş ağırlıkların kullanımı, bizim modelimizin daha az veriyle eğitilmesini ve daha hızlı bir şekilde yakınsamasını sağladı.
- Yüksek düzeyde özellik çıkarımı yeteneği, solar panellerdeki sorunların tespitinde faydalı oldu. Faydalı olma sebebi görsel veriler üzerindeki kompleks desenleri tanımlama üzerineydi.

### IV. MODEL DETAYI


#### A. Veri Seti

- Eğitim için toplam 885 dosya içeren 6 farklı sınıftan oluşan bir veri seti kullanıldı.
- Eğitim için 708 dosya, doğrulama için ise 177 dosya kullanıldı.
- Eğitim süreci boyunca veri seti, TensorFlow'da bulunan veri yükleyici (Data Loader) aracılığıyla model için uygun formata getirildi.
- Eğitim setinde 6 adet sınıf bulunmaktadır.
  - Bird-drop
  - Clean
  - Dusty
  - Electrical-damage
  - Physical-Damage
  - Snow-Covered

#### B. Model Mimarisi ve Parametreler

- Kullanılan model: VGG16.

- Toplam parametre sayısı: 14,760,858.
- Eğitilebilir parametre sayısı: 7,125,594.
- Eğitilmeyen parametre sayısı: 7,635,264.



#### C. Eğitim Süreci

- Model, 15 epoch boyunca eğitildi.
- Eğitim sırasında kullanılan optimizasyon algoritması: Adam optimizer.

$$m_t = \beta_1 * m_{t-1} + (1 - \beta_1) * \nabla w_t$$

$$v_t = \beta_2 * v_{t-1} + (1 - \beta_2) * (\nabla w_t)^2$$

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t} \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t}$$


$$w_{t+1} = w_t - \frac{\eta}{\sqrt{\hat{v}_t + \epsilon}} * \hat{m}_t$$

- Kayıp fonksiyonu olarak sparse categorical crossentropy kullanıldı.

$$\text{Loss} = -\frac{1}{\text{output size}} \sum_{i=1}^{\text{output size}} y_i \cdot \log \hat{y}_i + (1 - y_i) \cdot \log (1 - \hat{y}_i)$$

#### D. Eğitim Parametreleri

- 1) Eğitim için 15 epoch kullanıldı.
- 2) Early stopping kullanıldı: eğer doğrulama kaybı (val\_loss) 3 epoch boyunca belirtilen miktardan daha az düşmezse eğitim durduruldu.



#### E. Eğitim Süresi

- 1) Her bir epoch'un eğitim süresi değişkenlik gösterdi ancak genel olarak her bir epoch ortalama 10-14 saniye sürdü.

#### F. Doğruluk Parametreleri

- 1) Eğitim doğruluğu (accuracy): %98.02
- 2) Eğitim hata (loss): 0.0723
- 3) Doğrulama doğruluğu (validation accuracy): %83.05
- 4) Doğrulama hata (validation loss): 0.6560

#### G. Sonuç

Yapılan çalışma, güneş panellerinin görüntülerini kullanarak arıza tespit ve sınıflandırma amacıyla sinir ağı tabanlı bir model geliştirilmesini içermektedir. Bu model, güneş panellerinin doğal ve yapay hasarlarını tespit edebilme yeteneğine sahiptir ve erken teşhis ile bakım maliyetlerini azaltabilir.

Geliştirilen model, güneş panellerinin görüntülerini kullanarak altı farklı sınıftaki sorunları tanımlayabilir: Kuş pislikleri, temiz paneller, tozlu paneller, elektriksel hasarına sahip paneller, fiziksel hasara sahip paneller ve karla kaplı paneller. Bu sınıflandırma, panellerin bakım ve onarım süreçlerini optimize etmek için değerli bilgiler sunmaktadır.

Eğitim ve değerlendirme süreçlerinde kullanılan veri seti, modelin güvenilirliğini ve performansını doğrulamak için çeşitli koşulları içermektedir. Model, eğitim ve doğrulama veri setlerinde yüksek doğruluk oranları elde etmiş ve arıza tespiti konusunda etkili olduğunu kanıtlamıştır.

Bu çalışma, güneş enerjisi endüstrisinde bakım maliyetlerini azaltmak ve enerji üretimini optimize etmek için yapay zeka ve görüntü işleme tekniklerinin kullanımının potansiyelini vurgular. Gelecekte, benzer teknolojilerin daha geniş çapta benimsenmesiyle, güneş enerjisi sistemlerinin verimliliği ve sürdürülebilirliği artabilir.

#### REFERANSLAR

- [1] <https://enerji.gov.tr/eigm-venilenebilir-enerji-kaynaklar-gunes>, Erişim 19 Mart 2024. (references)
- [2] <https://builtin.com/machine-learning/vgg16>, Erişim 19 Mart 2024. (references)
- [3] <https://datascience.stackexchange.com/questions/73929/what-are-advantages-or-disadvantages-of-training-deep-learning-model-from-scratch>, Erişim 19 Mart 2024
- [4] <https://datascience.stackexchange.com/questions/73929/what-are-advantages-or-disadvantages-of-training-deep-learning-model-from-scratch>, Erişim 19 Mart 2024
- [5] <https://datascience.stackexchange.com/questions/73929/what-are-advantages-or-disadvantages-of-training-deep-learning-model-from-scratch>, Erişim 19 Mart 2024